

# Aprendizaje Automático en Problemas del Mundo Real

Predicción de Riesgo Cardíaco con Privacidad, Explicabilidad y Equidad

Marcos Francés Requena<sup>\*</sup>

Luna Camacho Boluda<sup>\*\*</sup>

Irene Fátima Robles Cano<sup>\*\*\*</sup>

Ángel Adrián Bustios Cancino<sup>\*\*\*\*</sup>

Grado en Ingeniería en Inteligencia Artificial

Escuela Politécnica Superior, Universidad de Alicante

Aprendizaje Avanzado — Curso 2025/2026

## Resumen

*Las enfermedades cardiovasculares constituyen una de las principales causas de mortalidad global, lo que motiva el desarrollo de sistemas de diagnóstico automático fiables. Este trabajo aborda la predicción de riesgo cardíaco sobre el UCI Heart Disease Dataset (303 instancias, 13 variables clínicas), un conjunto de datos reducido con desbalance moderado de clases y datos médicos sensibles. Se identifican tres problemáticas principales: privacidad en entornos distribuidos, escasez de datos con desbalance de clases, y falta de transparencia en los modelos. Para abordarlas, se propone un esquema de aprendizaje federado con agregación FedAvg, el uso de SMOTETomek como técnica de balanceo, y el análisis de explicabilidad mediante SHAP sobre un clasificador Random Forest. Se evalúan además SVM con distintos kernels, Gradient Boosting y AdaBoost mediante GridSearch con validación cruzada estratificada. El mejor modelo obtenido es SVM con kernel RBF ( $AUC-ROC = 0,9609$ ,  $Recall = 0,8571$ ), superando al baseline de Regresión Logística en más de 10 puntos porcentuales en Recall. El análisis SHAP identifica el resultado de la prueba de talio, el tipo de dolor torácico, el número de vasos y la depresión del segmento ST como las variables más relevantes, alineadas con la literatura clínica. El análisis de fairness revela un sesgo sistemático por sexo ( $Disparate Impact Ratio = 0,2697$ ), evidenciando la necesidad de evaluar la equidad como parte del protocolo estándar en sistemas de apoyo al diagnóstico médico.*

**Palabras clave:** aprendizaje automático, privacidad diferencial, aprendizaje federado, SHAP, desbalance de clases, dataset UCI Heart Disease.

---

<sup>\*</sup>mfr73@alu.ua.es

<sup>\*\*</sup>lcb52@alu.ua.es

<sup>\*\*\*</sup>ifrc1@alu.ua.es

<sup>\*\*\*\*</sup>aabc2@alu.ua.es

# Índice

|                                                                |           |
|----------------------------------------------------------------|-----------|
| <b>1. Introducción</b>                                         | <b>3</b>  |
| <b>2. Trabajo Relacionado</b>                                  | <b>3</b>  |
| 2.1. Trabajos sobre el problema abordado . . . . .             | 3         |
| 2.2. Técnicas para la problemática de privacidad . . . . .     | 3         |
| 2.3. Técnicas para la problemática de XAI . . . . .            | 3         |
| <b>3. Descripción del Problema y los Datos</b>                 | <b>4</b>  |
| 3.1. Definición formal de la tarea . . . . .                   | 4         |
| 3.2. Dataset . . . . .                                         | 4         |
| 3.3. Análisis exploratorio (EDA) . . . . .                     | 5         |
| 3.4. Problemáticas identificadas . . . . .                     | 7         |
| <b>4. Metodología</b>                                          | <b>7</b>  |
| 4.1. Preprocesamiento . . . . .                                | 7         |
| 4.2. Modelo <i>baseline</i> : Regresión Logística . . . . .    | 7         |
| 4.3. Tratamiento de privacidad: Aprendizaje Federado . . . . . | 8         |
| 4.4. Tratamiento de escasez: Random Forest . . . . .           | 8         |
| 4.5. Modelos alternativos . . . . .                            | 8         |
| 4.6. Tratamiento de explicabilidad: SHAP . . . . .             | 9         |
| <b>5. Experimentos y Resultados</b>                            | <b>9</b>  |
| 5.1. Configuración experimental . . . . .                      | 9         |
| 5.2. GridSearch sobre todos los modelos . . . . .              | 9         |
| 5.3. Explicabilidad: análisis SHAP . . . . .                   | 12        |
| 5.4. Curvas de privacidad-utilidad . . . . .                   | 15        |
| 5.5. Análisis de <i>fairness</i> . . . . .                     | 15        |
| <b>6. Discusión</b>                                            | <b>17</b> |
| 6.1. Interpretación de los resultados . . . . .                | 17        |
| 6.2. Limitaciones . . . . .                                    | 18        |
| 6.3. Implicaciones éticas, legales y sociales . . . . .        | 18        |
| <b>7. Conclusiones</b>                                         | <b>19</b> |
| <b>A. Contribución individual</b>                              | <b>21</b> |
| <b>B. Enlace al repositorio</b>                                | <b>21</b> |
| <b>C. Uso de herramientas de IA generativa</b>                 | <b>21</b> |

## 1. Introducción

Las enfermedades cardiovasculares continúan siendo una de las principales causas de mortalidad a nivel global. Sin embargo, la aplicación de modelos de IA en cardiología se enfrenta a la barrera de su naturaleza de “caja negra”: en un entorno donde las decisiones afectan vidas humanas, la falta de transparencia impide que los profesionales de la salud confíen plenamente en las predicciones del sistema. El problema central es cerrar la brecha entre alto rendimiento predictivo y la necesidad de entender el razonamiento subyacente, especialmente con conjuntos de datos tabulares pequeños que comprometen la estabilidad del modelo.

Esta problemática trasciende el ámbito técnico hacia las implicaciones éticas y legales. Bajo el RGPD, los pacientes tienen derecho a una explicación sobre decisiones automatizadas que afecten su salud. Además, el uso de datos médicos sensibles plantea desafíos de privacidad y el riesgo de crear o agravar sesgos que podrían derivar en desigualdades. Un modelo debe ser no solo preciso, sino también equitativo, privado y explicable.

En respuesta, este trabajo propone un sistema de predicción de riesgo cardíaco sobre el *UCI Heart Disease Dataset*, integrando aprendizaje federado para preservar la privacidad, SMOTE-Tomek para el balanceo de clases, y SHAP para la explicabilidad. Se adopta una metodología de múltiples ejecuciones para mitigar la inestabilidad propia de datasets médicos pequeños, y se incluye un análisis de equidad por sexo y edad.

## 2. Trabajo Relacionado

### 2.1. Trabajos sobre el problema abordado

El uso de datos médicos para clasificación, como en el dataset UCI Heart Disease, plantea desafíos de privacidad, calidad de datos y escasez de muestras. Vatsalan et al. (2014) exploran técnicas criptográficas para procesar datos médicos sensibles sin revelar información original [2]; Yadav et al. (2014) proponen el historial médico como biometría de autenticación [3]. En cuanto a la escasez de datos, Shaikhina y Khovanova (2017) analizan el sobreajuste en datasets pequeños con redes neuronales [4], y Rather et al. (2024) revisan técnicas como transferencia de aprendizaje y regularización para mitigarlo [5].

### 2.2. Técnicas para la problemática de privacidad

Normativas como GDPR e HIPAA restringen la centralización de datos médicos [1]. Los métodos criptográficos permiten operar sobre datos sin exponerlos, con un coste computacional elevado. El aprendizaje federado ha emergido como solución más escalable: los datos permanecen en los dispositivos locales y solo se comparten los parámetros del modelo [6]. Frameworks como Flower o TensorFlow Federated facilitan su implementación. No obstante, presenta desafíos como la heterogeneidad de datos entre clientes y la posible filtración por gradientes, lo que motiva su combinación con privacidad diferencial o cifrado seguro [1].

### 2.3. Técnicas para la problemática de XAI

En el ámbito médico, la explicabilidad es un requisito fundamental para garantizar la equidad, mitigar sesgos y establecer la confianza clínica [7]. LIME generó explicaciones locales rápidas pero carece de consistencia global, presenta fragilidad ante ruido y puede generar explicaciones inestables [8, 10]. SHAP, basado en la teoría de juegos cooperativos, garantiza consistencia matemática y unifica interpretabilidad local y global [8, 9]. Sin embargo, la mayoría de modelos proporcionan importancia estática, omitiendo la incertidumbre inherente a cualquier diagnóstico [11, 7]. Este trabajo combina modelos de ensamblaje (Random Forest) con SHAP e integra cuantificación de incertidumbre y métricas de equidad, siguiendo el enfoque de sustitutos parciales de Wang (2019) [12].

### 3. Descripción del Problema y los Datos

#### 3.1. Definición formal de la tarea

La tarea es una clasificación binaria supervisada. Dado un vector  $\mathbf{x} \in \mathbb{R}^{13}$ , se aprende  $f : \mathbb{R}^{13} \rightarrow \{0, 1\}$  minimizando la pérdida de entropía cruzada. La variable objetivo binariza *num* (valores 0–4) según:

$$y_i = \begin{cases} 0 & \text{si } num_i = 0 \quad (\text{sano}) \\ 1 & \text{si } num_i > 0 \quad (\text{enfermedad}) \end{cases} \quad (1)$$

La distribución resultante es 160 muestras sanas (clase 0) frente a 137 con enfermedad (clase 1), introduciendo un desbalance moderado.

#### 3.2. Dataset

El dataset utilizado es el **UCI Heart Disease Dataset** (id=45), correspondiente a datos clínicos del Cleveland Clinic Foundation. La Tabla 1 resume sus características principales.

Tabla 1: Características del dataset.

| Característica    | Valor                                                                             |
|-------------------|-----------------------------------------------------------------------------------|
| Fuente            | UCI Machine Learning Repository, id=45                                            |
| Instancias        | 303 (297 tras eliminar nulos)                                                     |
| Features          | 13 variables clínicas                                                             |
| Variable objetivo | <i>num</i> binarizada: 0 (sano) / 1 (enfermedad)                                  |
| Distribución      | 53,87 % clase 0 / 46,13 % clase 1                                                 |
| Valores ausentes  | <i>ca</i> (4 nulos) y <i>thal</i> (2 nulos); eliminados con <code>dropna()</code> |
| Licencia          | CC BY 4.0                                                                         |

Las 13 variables se dividen en **numéricas continuas** (*age*, *trestbps*, *chol*, *thalach*, *oldpeak*, *ca*) y **categorías** (*sex*, *cp*, *fbs*, *restecg*, *exang*, *slope*, *thal*).

En cuanto a las **consideraciones éticas**, los pacientes tienen edades entre 29 y 77 años con una proporción mayoritaria de hombres (67,99 %), lo que constituye un sesgo de selección que puede limitar la generalización del modelo a poblaciones femeninas. Los datos proceden de los años 1980–1990 y su uso aquí tiene finalidad exclusivamente académica.

### 3.3. Análisis exploratorio (EDA)

**Distribución de la variable objetivo.** La Figura 1 muestra la distribución del *target* binarizado: 160 pacientes sanos y 137 enfermos. En contexto clínico, incluso este desbalance moderado puede sesgar el modelo hacia la clase mayoritaria y penalizar el Recall de la clase positiva.




Figura 1: Distribución de la variable objetivo binarizada.

La Figura 2 muestra las distribuciones de las variables continuas. *Age* presenta distribución bimodal; *trestbps* y *chol* son aproximadamente normales con colas hacia la derecha; *oldpeak* exhibe asimetría positiva y valores atípicos cercanos a 6; *ca* es discreta (0–3).




Figura 2: Distribución de las variables numéricas.

Los boxplots (Figura 3) confirman valores atípicos relevantes: *chol* máximo 564 mg/dl (p75: 275), *trestbps* máximo 200 mm Hg (p75: 140) y *oldpeak* máximo 6,2 (p75: 1,6), lo que justifica el uso de la mediana como estimador de imputación.




Figura 3: Boxplots de las variables numéricas continuas. Se aprecian valores atípicos en *chol*, *trestbps* y *oldpeak*.

La matriz de correlación (Figura 4) revela que las variables con mayor relación lineal con *num* son *ca* ( $r = 0,52$ ), *thal* ( $r = 0,51$ ), *oldpeak* ( $r = 0,50$ ), *cp* ( $r = 0,40$ ) y *exang* ( $r = 0,39$ ); mientras que *thalach* presenta correlación negativa ( $r = -0,42$ ) y *chol* y *fbs* correlaciones casi nulas ( $r < 0,07$ ).




Figura 4: Matriz de correlación de Pearson entre todas las variables del dataset.

### 3.4. Problemáticas identificadas

**Privacidad.** En un escenario real, los modelos de predicción cardíaca se entrenarían con datos de múltiples hospitales, lo que implica compartir información altamente confidencial. Esto entra en conflicto directo con el RGPD (art. 9, datos de salud) y el AI Act, que clasifica estos sistemas como de alto riesgo. La arquitectura federada propuesta simula este escenario, permitiendo que cada cliente entrene localmente sin exponer sus datos.

**Escasez de datos y desbalance de clases.** Con solo 297 instancias válidas, el modelo es propenso al sobreajuste. Aunque el desbalance no es extremo (53,87 % / 46,13 %), en contexto clínico un falso negativo —clasificar como sano a un enfermo— tiene consecuencias mucho más graves que un falso positivo, por lo que maximizar el Recall sobre la clase positiva es prioritario.

## 4. Metodología

### 4.1. Preprocesamiento

El pipeline de preprocesamiento es reproducible y libre de *data leakage*: todos los transformadores se ajustan exclusivamente sobre el conjunto de entrenamiento. Incluye eliminación de filas con nulos, binarización del *target*, división train/test estratificada (80/20, `random_state=42`), imputación, escalado y codificación.

Las variables numéricas continuas (`age`, `trestbps`, `chol`, `thalach`, `oldpeak`, `ca`) se imputan con la mediana —robusta ante los *outliers* identificados— y se estandarizan con `StandardScaler`. Las variables categóricas (`sex`, `cp`, `fbs`, `restecg`, `exang`, `slope`, `thal`) se imputan con la moda y se codifican con `OneHotEncoder(drop='first')` para evitar multicolinealidad.

### Balanceo con SMOTETomek

Para compensar el desbalance de clases se aplica **SMOTETomek** exclusivamente sobre el conjunto de entrenamiento. SMOTE genera muestras sintéticas de la clase minoritaria mediante interpolación lineal entre una muestra  $\mathbf{x}_i$  y un vecino aleatorio  $\mathbf{x}_{nn}$  ( $k = 5$ ):

$$\mathbf{x}_{\text{syn}} = \mathbf{x}_i + \lambda \cdot (\mathbf{x}_{nn} - \mathbf{x}_i), \quad \lambda \sim \mathcal{U}(0, 1) \quad (2)$$

A continuación, los **Tomek Links** eliminan pares de muestras de clases distintas que son vecinas mutuamente más cercanas, limpiando la frontera de decisión [13]. Esta combinación es más robusta que SMOTE estándar: aumenta la clase minoritaria y filtra instancias conflictivas [14]. La distribución antes y después se recoge en la Tabla 2.

Tabla 2: Distribución de clases en entrenamiento antes y después de SMOTETomek.

| Conjunto              | Clase 0 | Clase 1 | Total |
|-----------------------|---------|---------|-------|
| Antes de SMOTETomek   | 128     | 109     | 237   |
| Después de SMOTETomek | [117]   | [117]   | [234] |

### 4.2. Modelo *baseline*: Regresión Logística

La **Regresión Logística** sirve como modelo de referencia por su baja complejidad, adecuada al tamaño reducido del dataset, y por sus coeficientes directamente interpretables. El modelo estima la probabilidad de enfermedad cardíaca mediante:

$$\hat{p}(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^\top \mathbf{x} + b)}} \quad (3)$$

Se minimiza la entropía cruzada binaria con regularización  $\ell_2$  (parámetro  $C = 1,0$ ), mediante el solver **lbfgs**. La evaluación se realiza con validación cruzada estratificada de 5 *folds*, priorizando AUC-ROC y Recall.

### 4.3. Tratamiento de privacidad: Aprendizaje Federado

Se propone un esquema de **aprendizaje federado** con  $K$  clientes (hospitales) donde los datos permanecen distribuidos y solo se transmiten los parámetros del modelo [6]. Cada cliente  $k$  recibe una partición estratificada  $\mathcal{D}_k$  y minimiza localmente:

$$\mathcal{L}_k(\mathbf{w}_k, b_k) = -\frac{1}{n_k} \sum_{i=1}^{n_k} [y_i \log \hat{p}_k(\mathbf{x}_i) + (1 - y_i) \log(1 - \hat{p}_k(\mathbf{x}_i))] + \frac{\lambda}{2} \|\mathbf{w}_k\|^2 \quad (4)$$

El servidor agrega mediante **FedAvg** (promedio ponderado por tamaño de partición):

$$\mathbf{w}_{\text{global}} = \frac{\sum_{k=1}^K n_k \cdot \mathbf{w}_k}{\sum_{k=1}^K n_k} \quad (5)$$

El proceso se repite durante  $R$  rondas. En este trabajo:  $K = 10$ ,  $R = 15$ ,  $E = 100$  épocas locales,  $\eta = 0,05$ ,  $\lambda = 0,01$ .

### Federado + SMOTETomek

Para abordar simultáneamente privacidad y desbalance, cada cliente aplica SMOTETomek localmente sobre su partición antes del entrenamiento, obteniendo  $\mathcal{D}_k^{\text{bal}}$ . El balanceo es completamente local: ninguna muestra —real ni sintética— abandona el cliente. La agregación FedAvg opera solo sobre parámetros. El cliente  $k$  aplica SMOTETomek únicamente si  $\min(|\mathcal{D}_k^+|, |\mathcal{D}_k^-|) \geq k_{\text{neighbors}} + 1 = 6$ .

### 4.4. Tratamiento de escasez: Random Forest

El **Random Forest** es el clasificador principal para la problemática de escasez de datos. Combina  $T$  árboles entrenados sobre muestras *bootstrap*, con selección aleatoria de  $m = \lfloor \sqrt{d} \rfloor$  características en cada nodo. La predicción final es el promedio de probabilidades de los árboles:

$$\hat{p}(\mathbf{x}) = \frac{1}{T} \sum_{t=1}^T \hat{p}_t(\mathbf{x}) \quad (6)$$

La doble aleatoriedad (muestras y características) reduce la varianza sin incrementar el sesgo, haciéndolo robusto ante el sobreajuste en datasets pequeños. Los árboles se construyen maximizando la reducción de impureza de Gini. Se usa  $T = 500$  como configuración inicial, optimizando el resto de hiperparámetros mediante GridSearch.

### 4.5. Modelos alternativos

#### Support Vector Machine (SVM)

SVM busca el hiperplano de máximo margen que separa las dos clases. La forma primal con variables de holgura es:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \quad \text{s.a.} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \quad (7)$$

Se evalúan kernels lineal, RBF ( $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$ ) y polinomial.



## Gradient Boosting

Construye el modelo de forma secuencial: cada árbol  $h_m$  aprende a predecir los pseudo-residuos del modelo acumulado  $F_{m-1}$ :

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta \cdot h_m(\mathbf{x}), \quad r_{im} = y_i - \hat{p}_{m-1}(\mathbf{x}_i) \quad (8)$$

La regularización se controla mediante la tasa de aprendizaje  $\eta$ , profundidad máxima  $d_{\max}$  y submuestreo. Configuración de referencia:  $M = 100$ ,  $\eta = 0,1$ ,  $d_{\max} = 3$ .

### 4.6. Tratamiento de explicabilidad: SHAP

SHAP se aplica sobre el Random Forest del GridSearch mediante **TreeExplainer**. El valor SHAP de la característica  $j$  para la muestra  $\mathbf{x}$  cuantifica su contribución marginal promedio sobre todas las coaliciones posibles:

$$\phi_j(f, \mathbf{x}) = \sum_{S \subseteq \mathcal{F} \setminus \{j\}} \frac{|S|! (|\mathcal{F}| - |S| - 1)!}{|\mathcal{F}|!} [f_{S \cup \{j\}}(\mathbf{x}) - f_S(\mathbf{x})] \quad (9)$$

Los valores SHAP satisfacen cuatro propiedades que los hacen idóneos para contextos clínicos: **eficiencia** (la suma reproduce la predicción), **simetría**, **nulidad** y **aditividad**. TreeExplainer calcula estos valores exactamente en tiempo  $\mathcal{O}(T \cdot L \cdot d)$ , aprovechando la estructura de árbol. Se generan dos niveles de análisis: (1) importancia global como media del valor absoluto SHAP sobre el conjunto de test, y (2) explicación local mediante *waterfall plots* para predicciones individuales, cubriendo los requisitos de trazabilidad del RGPD [1].

## 5. Experimentos y Resultados

### 5.1. Configuración experimental

Todos los experimentos usan `SEED = 42` para reproducibilidad. Entorno: Python 3.12, `scikit-learn` 1.6, `imbalanced-learn` 0.13, `shap` 0.47, `numpy` 2.2. División 80/20 estratificada; SMOTETomek aplicado solo sobre entrenamiento. Evaluación mediante validación cruzada estratificada de  $k = 5$  *folds*, reportando media  $\pm$  desviación estándar.

### 5.2. GridSearch sobre todos los modelos

Se realizó un GridSearch exhaustivo (CV= 5, SMOTETomek) para siete configuraciones de modelos. La Tabla 3 resume las métricas del mejor estimador de cada uno.

Tabla 3: Comparativa de modelos tras GridSearch (CV= 5, SMOTETomek).

| Modelo                   | AUC-ROC             | F1                  | Recall              | Precision           | Accuracy            |
|--------------------------|---------------------|---------------------|---------------------|---------------------|---------------------|
| <i>Baseline</i> (LogReg) | 0,8906 $\pm$ 0,0721 | 0,7861 $\pm$ 0,0845 | 0,7511 $\pm$ 0,1100 | 0,8349 $\pm$ 0,0929 | 0,8140 $\pm$ 0,0746 |
| SVM lineal               | 0,9587 $\pm$ 0,0252 | 0,8727 $\pm$ 0,0669 | 0,8571 $\pm$ 0,1098 | 0,8889 $\pm$ 0,0262 | 0,8833 $\pm$ 0,0397 |
| SVM RBF                  | 0,9609 $\pm$ 0,0166 | 0,8727 $\pm$ 0,0176 | 0,8571 $\pm$ 0,0477 | 0,8889 $\pm$ 0,0297 | 0,8833 $\pm$ 0,0083 |
| SVM polinomial           | 0,9386 $\pm$ 0,0260 | 0,8519 $\pm$ 0,0466 | 0,8214 $\pm$ 0,0877 | 0,8846 $\pm$ 0,0475 | 0,8667 $\pm$ 0,0252 |
| SVM sigmoide             | 0,9576 $\pm$ 0,0275 | 0,8727 $\pm$ 0,0436 | 0,8571 $\pm$ 0,0843 | 0,8889 $\pm$ 0,0271 | 0,8833 $\pm$ 0,0254 |
| Random Forest            | 0,9269 $\pm$ 0,0236 | 0,7692 $\pm$ 0,0303 | 0,7143 $\pm$ 0,0659 | 0,8333 $\pm$ 0,0282 | 0,8000 $\pm$ 0,0222 |
| Gradient Boosting        | 0,9196 $\pm$ 0,0209 | 0,8000 $\pm$ 0,0253 | 0,7857 $\pm$ 0,0534 | 0,8148 $\pm$ 0,0237 | 0,8167 $\pm$ 0,0166 |
| AdaBoost                 | 0,9129 $\pm$ 0,0159 | 0,7778 $\pm$ 0,0202 | 0,7500 $\pm$ 0,0516 | 0,8077 $\pm$ 0,0228 | 0,8000 $\pm$ 0,0135 |

Las Figuras 5–9 presentan distintas visualizaciones comparativas de los resultados.




Figura 5: Comparativa de métricas para el *baseline* y los siete modelos. Barras de error: desviación estándar en CV= 5.




Figura 6: Mapa de calor de métricas por modelo. Verde: valores altos; amarillo: valores bajos.




Figura 7: Ranking de modelos por AUC-ROC (CV= 5). La línea discontinua roja marca el umbral de 0,90.




Figura 8: Distribución de AUC-ROC, F1 y Recall en los 5 *folds* de CV para cada modelo.




Figura 9: *Spider chart* multidimensional. Un área mayor indica mejor rendimiento global.

La Tabla 4 recoge los mejores hiperparámetros encontrados por GridSearch.

Tabla 4: Mejores hiperparámetros por GridSearch (criterio: AUC-ROC).

| Modelo            | Mejores hiperparámetros                                                                                                      |
|-------------------|------------------------------------------------------------------------------------------------------------------------------|
| SVM lineal        | <code>{'C': 0.01}</code>                                                                                                     |
| SVM RBF           | <code>{'C': 1, 'gamma': 0.01}</code>                                                                                         |
| SVM polinomial    | <code>{'C': 1, 'coef0': 0, 'degree': 3}</code>                                                                               |
| SVM sigmoide      | <code>{'C': 0.1, 'coef0': 0, 'gamma': 'scale'}</code>                                                                        |
| Random Forest     | <code>{'max_depth': None, 'max_features': 'sqrt', 'min_samples_leaf': 1, 'min_samples_split': 2, 'n_estimators': 200}</code> |
| Gradient Boosting | <code>{'learning_rate': 0.01, 'max_depth': 3, 'min_samples_split': 2, 'n_estimators': 200, 'subsample': 0.8}</code>          |
| AdaBoost          | <code>{'estimator__max_depth': 2, 'learning_rate': 0.1, 'n_estimators': 200}</code>                                          |

### 5.3. Explicabilidad: análisis SHAP

SHAP se aplica sobre el mejor Random Forest del GridSearch con **TreeExplainer**. La Figura 10 muestra la importancia global y la dirección del efecto de cada variable.




Figura 10: SHAP *summary plot* (beeswarm). Rojo: valor alto de la característica; azul: valor bajo.




Figura 11: Importancia global de características según  $|\phi_i|$  sobre el conjunto de test.




Figura 12: SHAP *dependence plots* para las cuatro características más relevantes.




Figura 13: SHAP *waterfall plot* para el paciente 0 del conjunto de test.

## 5.4. Curvas de privacidad–utilidad

Se añade ruido gaussiano diferencial al conjunto de entrenamiento con distintos niveles de  $\varepsilon$  ( $\sigma = \Delta f / \varepsilon$ ), promediando 10 realizaciones independientes por nivel.




Figura 14: Curva de privacidad–utilidad para el Random Forest. La línea verde discontinua marca el AUC-ROC sin ruido.




Figura 15: Curva de privacidad–utilidad comparativa entre *baseline*, Random Forest y Gradient Boosting.

## 5.5. Análisis de *fairness*

Se evalúa la equidad respecto al atributo sensible *sexo*. Las Tablas 5 y 6 detallan las métricas por grupo y los indicadores de equidad.

Tabla 5: Métricas de rendimiento por grupo sensible (*sexo*) en test.

| Modelo             | AUC-ROC Global | F1 Global | Recall Global | AUC Mujeres / Hombres | F1 Mujeres / Hombres |
|--------------------|----------------|-----------|---------------|-----------------------|----------------------|
| Baseline (LogReg)  | 0,9498         | 0,8519    | 0,8214        | 1,0000 / 0,9075       | 0,8000 / 0,8571      |
| SVM RBF (mejor GS) | 0,9609         | 0,8727    | 0,8571        | 1,0000 / 0,9350       | 1,0000 / 0,8571      |

Tabla 6: Indicadores de equidad (valores ideales entre paréntesis).

| Indicador                                        | <i>Baseline</i> | SVM RBF |
|--------------------------------------------------|-----------------|---------|
| Demographic Parity Difference ( $\downarrow 0$ ) | 0,4801          | 0,4275  |
| Equal Opportunity Difference ( $\downarrow 0$ )  | 0,1733          | 0,1600  |
| Equalized Odds Difference ( $\downarrow 0$ )     | 0,1875          | 0,1875  |
| Disparate Impact Ratio ( $\uparrow 1$ )          | 0,1798          | 0,2697  |




Figura 16: Mapa de calor de métricas por grupo sensible para *baseline* (izq.) y mejor modelo (der.).




Figura 17: Indicadores de *fairness*. La línea roja discontinua marca el umbral de equidad aceptable (0,10).






Figura 18: Curvas ROC por grupo sensible (*sexo*) para *baseline* (izq.) y mejor modelo (der.).

## 6. Discusión

### 6.1. Interpretación de los resultados

Los resultados obtenidos muestran que es posible construir un sistema de predicción de riesgo cardíaco con rendimiento competitivo sobre el dataset UCI Heart Disease incluso bajo las restricciones que impone un conjunto de datos pequeño y sensible. Tras el GridSearch exhaustivo con validación cruzada estratificada de 5 *folds* sobre el conjunto balanceado con SMOTETomek, el modelo con mayor AUC-ROC es el SVM con kernel RBF ( $0,9609 \pm 0,0166$ ), seguido de cerca por el SVM lineal y el SVM sigmoide ( $0,9587$  y  $0,9576$  respectivamente), todos ellos por encima del umbral de referencia de  $0,90$ . El *baseline* de Regresión Logística ocupa la cuarta posición del ranking con un AUC-ROC de  $0,9498$ , lo que constituye ya un punto de partida sólido y pone de manifiesto que el dataset, pese a su tamaño reducido, es relativamente bien separable.

Desde el punto de vista clínico, la métrica más relevante es el Recall sobre la clase positiva, dado que un falso negativo —clasificar como sano a un paciente enfermo— entraña consecuencias mucho más graves que un falso positivo. En este indicador, los modelos SVM con kernels lineal, RBF y sigmoide alcanzan conjuntamente el valor más alto ( $0,8571$ ), superando al *baseline* ( $0,7511$ ) en más de 10 puntos porcentuales. Esto implica que, con el mejor modelo, aproximadamente uno de cada siete pacientes enfermos quedaría sin detectar, frente a uno de cada cuatro con el modelo de referencia, una mejora sustancial en términos de seguridad diagnóstica. En términos de F1 y Accuracy, los tres SVM mencionados alcanzan igualmente los valores más altos ( $F1 = 0,8727$ ;  $Accuracy = 0,8833$ ), mientras que Random Forest, Gradient Boosting y AdaBoost quedan entre 4 y 10 puntos por debajo en F1, lo que sugiere que los modelos de *ensemble* no explotan tan eficientemente el espacio de características en este dataset de tamaño reducido como lo hacen los métodos de margen máximo.

El análisis SHAP aplicado sobre el mejor Random Forest del GridSearch (200 estimadores) revela que las variables con mayor impacto global en las predicciones son, por orden de importancia media del valor absoluto SHAP: el resultado de la prueba de talio con defecto reversible (*cat\_thal\_7.0*), el tipo de dolor torácico asintomático (*cat\_cp\_4.0*), el número de vasos coloreados por fluoroscopia (*num\_ca*) y la depresión del segmento ST en ejercicio (*num\_olddpeak*). Este resultado es coherente con la matriz de correlación de Pearson identificada en el análisis exploratorio, donde estas mismas variables presentaban los valores más altos ( $r$  entre  $0,40$  y  $0,52$  con la variable objetivo), y está respaldado por la literatura clínica, en la que la prueba de talio, la angiografía coronaria y la respuesta electrocardiográfica al ejercicio son marcadores establecidos de enfermedad coronaria. La explicabilidad local mediante *waterfall plots* —ilustrada para el paciente 0 del conjunto de test, cuya predicción parte de  $E[f(x)] = 0,497$  y se desplaza hacia

valores bajos de riesgo por la ausencia de los factores más discriminantes— permite identificar exactamente qué variables conducen a una predicción concreta, proporcionando al personal clínico una herramienta de transparencia directamente utilizable en la toma de decisiones.

En cuanto al compromiso entre privacidad y rendimiento, la curva de privacidad–utilidad muestra que el AUC-ROC del Random Forest cae bruscamente para valores de  $\varepsilon$  muy bajos ( $\varepsilon \leq 0,1$ , régimen de alta privacidad), pero se estabiliza por encima de 0,85 a partir de  $\varepsilon \geq 1$ , aproximándose al valor sin ruido (AUC-ROC = 0,9213) para  $\varepsilon \geq 5$ . Este comportamiento se reproduce también en Gradient Boosting y en el *baseline*, aunque con una recuperación algo más rápida para la Regresión Logística en los niveles intermedios. En conjunto, estos resultados indican que es posible introducir un nivel moderado de privacidad diferencial sin una degradación significativa del rendimiento predictivo, lo que valida la viabilidad del esquema propuesto para escenarios distribuidos donde la privacidad constituye un requisito no negociable.

## 6.2. Limitaciones

La limitación más importante del trabajo es el tamaño del dataset: con únicamente 297 instancias válidas, los resultados de validación cruzada presentan desviaciones estándar elevadas—hasta  $\pm 0,0721$  en AUC-ROC para el *baseline* y  $\pm 0,0252$  para el SVM lineal—, lo que impide afirmar con certeza estadística la superioridad de un modelo sobre otro. La diferencia entre el mejor modelo (SVM RBF, AUC-ROC = 0,9609) y el peor (AdaBoost, AUC-ROC = 0,9129) es de apenas 4,8 puntos porcentuales, y los intervalos asociados a la desviación estándar se solapan considerablemente. La aplicación de SMOTETomek genera muestras sintéticas que, aunque filtradas por los Tomek links, no provienen de pacientes reales, lo que puede introducir patrones que no reflejan fielmente la distribución real de la población. Adicionalmente, el protocolo de evaluación, que utiliza el mismo conjunto de test como referencia durante el análisis de resultados, introduce un sesgo optimista en las métricas reportadas.

En cuanto a las técnicas aplicadas, el análisis SHAP asume que las contribuciones de las características son aditivas e independientes, supuesto que puede no cumplirse ante interacciones clínicas complejas entre variables como *cp* y *exang*, cuya correlación mutua ( $r = 0,38$ , visible en la matriz de Pearson) sugiere cierto grado de dependencia. La privacidad diferencial implementada añade ruido gaussiano directamente sobre los datos de entrenamiento con  $\sigma = \Delta f / \varepsilon$ , una aproximación que no cumple estrictamente la definición formal de  $(\varepsilon, \delta)$ -privacidad diferencial y que no protege frente a ataques sobre los gradientes del modelo, limitación relevante si el sistema se desplegara en un entorno de aprendizaje federado real. Finalmente, los datos del dataset corresponden a las décadas de 1980–1990 y a una población con predominio masculino (67,99 %), lo que limita la validez externa del modelo a poblaciones y contextos clínicos distintos de los originales.

## 6.3. Implicaciones éticas, legales y sociales

El análisis de *fairness* revela una disparidad significativa entre grupos según el atributo sensible sexo. El mejor modelo del GridSearch (SVM RBF) presenta un Disparate Impact Ratio de 0,2697, muy por debajo del umbral de 0,80 habitualmente empleado como criterio de equidad aceptable, y una Demographic Parity Difference de 0,4275, que aunque mejora ligeramente la del *baseline* (0,4801), sigue siendo muy elevada. El Equal Opportunity Difference se reduce de 0,1733 a 0,1600 con el mejor modelo, mientras que el Equalized Odds Difference se mantiene en 0,1875 en ambos casos, por encima del umbral de 0,10 de referencia en la literatura. Las curvas ROC desagregadas por sexo muestran que el modelo alcanza un AUC de 1,0000 para las mujeres frente a 0,9350 para los hombres; sin embargo, este resultado debe interpretarse con cautela dado el tamaño muy reducido del subgrupo femenino en el conjunto de test, ya que un AUC perfecto sobre una muestra pequeña puede ser un artefacto estadístico antes que una evidencia real de mayor capacidad discriminativa. En cualquier caso, la Demographic Parity Difference pone de manifiesto

que el sistema emite predicciones positivas con una frecuencia muy distinta entre hombres y mujeres, lo que en un entorno clínico real podría traducirse en una infradetección sistemática de la enfermedad cardíaca en pacientes femeninas, consecuencia directa de la sobrerrepresentación masculina en los datos de entrenamiento.

Desde el punto de vista legal, un sistema de apoyo al diagnóstico médico quedaría clasificado como sistema de IA de alto riesgo bajo el AI Act europeo (Anexo III, categoría 5), lo que implica obligaciones específicas: evaluación de conformidad previa al despliegue, documentación técnica detallada, supervisión humana efectiva y registro en la base de datos de la UE. El RGPD añade además el derecho del paciente a una explicación de las decisiones automatizadas que le afecten (artículo 22), requisito que el análisis SHAP contribuye a satisfacer pero que no cubre por sí solo: una explicación en términos de valores de Shapley, como la descomposición *waterfall* sobre la predicción individual, no es necesariamente comprensible para el paciente afectado sin mediación del personal clínico. En consecuencia, el sistema propuesto debe entenderse exclusivamente como una herramienta de apoyo a la decisión clínica, nunca como sustituto del juicio médico, y su despliegue requeriría validación clínica prospectiva sobre poblaciones representativas antes de cualquier uso real.

## 7. Conclusiones

Este trabajo demuestra que es posible construir un sistema de predicción de riesgo cardíaco preciso, explicable y respetuoso con la privacidad sobre el UCI Heart Disease Dataset, abordando simultáneamente tres problemáticas: privacidad en entornos distribuidos, escasez de muestras con desbalance, y necesidad de transparencia.

Una lección central es que la complejidad del modelo no es el factor determinante con datasets pequeños: la diferencia entre mejor y peor modelo es inferior a 5 puntos en AUC-ROC, indicando que el límite de rendimiento lo imponen el tamaño y la calidad de los datos, no la capacidad del clasificador.

El análisis SHAP identifica como variables más relevantes el resultado de talio (`cat_thal_7.0`), el dolor torácico asintomático (`cat_cp_4.0`), el número de vasos (`num_ca`) y la depresión del segmento ST (`num_oldpeak`), todas con respaldo clínico consolidado. La explicabilidad local mediante *waterfall plots* proporciona una herramienta de transparencia alineada con el RGPD y el AI Act.

La integración de SMOTETomek en el esquema federado resulta compatible con la preservación de la privacidad, al realizarse el balanceo localmente sin compartir muestras. La curva de privacidad-utilidad valida la viabilidad de privacidad diferencial moderada ( $\epsilon \geq 1$ ) sin degradación significativa del rendimiento.

El análisis de *fairness* evidencia un sesgo sistemático por sexo (Disparate Impact Ratio = 0,2697), subrayando que las métricas globales son insuficientes para validar sistemas de apoyo al diagnóstico: la evaluación desagregada por grupos sensibles debe ser parte del protocolo estándar.

## Referencias

- [1] N. Yadav, S. Pandey, A. Gupta, P. Dudani, S. Gupta y K. Rangarajan, “Data privacy in healthcare: In the era of artificial intelligence,” *Indian Dermatology Online Journal*, vol. 14, núm. 6, pp. 788–792, 2023. DOI:10.4103/idoj.idoj\_543\_23
- [2] D. Vatsalan, P. Christen y V. S. Verykios, “Designing an Algorithm to Preserve Privacy for Medical Record Linkage With Error-Prone Data,” *Proc. PAKDD*, Canberra, 2014. S2ID:36c4d82ab7bba7b71731e9b496440ba6e27e8021
- [3] P. Yadav, S. S. Sambare y S. Yadav, “Using Medical History Embedded in Biometrics Medical Card for User Identity Authentication,” *Int. J. Computer Applications*, vol. 95, núm. 14, pp. 25–31, 2014.
- [4] T. Shaikhina y N. A. Khovanova, “Handling limited datasets with neural networks in medical applications,” *Artificial Intelligence in Medicine*, vol. 75, pp. 51–63, 2017. DOI:10.1016/j.artmed.2016.12.003
- [5] I. H. Rather, S. Kumar y A. H. Gandomi, “Breaking the data barrier: a review of deep learning techniques for democratizing AI with small datasets,” *Artificial Intelligence Review*, vol. 57, núm. 226, 2024. DOI:10.1007/s10462-024-10859-3
- [6] Q. Yang, Y. Liu, T. Chen y Y. Tong, “Federated Machine Learning: Concept and Applications,” *ACM TIST*, vol. 10, núm. 2, pp. 1–19, 2019. DOI:10.1145/3298981
- [7] M. Mesinovic, P. Watkinson y T. Zhu, “Explainable AI for clinical risk prediction: a survey of concepts, methods, and modalities,” *arXiv:2308.08407*, 2023.
- [8] S. Mujawar, M. Sayed y A. Chaware, “Empowering Decision Making in Healthcare – A Comparative Analysis of XAI using SHAP and LIME,” *Proc. IEEE DELCON*, Nueva Delhi, 2024. DOI:10.1109/DELCON64804.2024.10867049
- [9] C. Zhang y L. Liu, “Machine learning prediction model for medical environment comfort based on SHAP and LIME,” *Scientific Reports*, vol. 15, núm. 1, pp. 39269, 2025. DOI:10.1038/s41598-025-22972-6
- [10] E. Tjoa y C. Guan, “A Survey on Explainable Artificial Intelligence (XAI): Toward Medical XAI,” *IEEE TNNLS*, vol. 32, núm. 11, pp. 4793–4814, 2021. DOI:10.1109/TNNLS.2020.3027314
- [11] M. I. Hossain et al., “Explainable AI for Medical Data: Current Methods, Limitations, and Future Directions,” *ACM Computing Surveys*, vol. 56, núm. 7, pp. 1–31, 2024. DOI:10.1145/3637487
- [12] T. Wang, “Gaining Free or Low-Cost Transparency with Interpretable Partial Substitute,” *Proc. ICML*, Long Beach, 2019, pp. 6505–6514.
- [13] T. Kosolwattana et al., “A self-inspected adaptive SMOTE algorithm (SASMOTE) for highly imbalanced data in healthcare,” *BioData Mining*, vol. 16, núm. 15, 2023. DOI:10.1186/s13040-023-00330-4
- [14] B. H. Aubaidan, R. A. Kadir y M. T. Ijab, “A Comparative Analysis of Smote and CSSF Techniques for Diabetes Classification,” *Journal of Computer Science*, vol. 20, núm. 6, pp. 1146–1165, 2024. DOI:10.3844/jcssp.2024.1146.1165

## A. Contribución individual

Tabla 7: Contribución de cada miembro del grupo.

| Miembro       | Contribución principal                          |
|---------------|-------------------------------------------------|
| Luna y Marcos | Secciones <a href="#">1</a> y <a href="#">2</a> |
| Irene         | Secciones <a href="#">3</a> y <a href="#">6</a> |
| Adrián        | Sección <a href="#">4</a>                       |
| Luna y Marcos | Sección <a href="#">5</a>                       |

## B. Enlace al repositorio

El código fuente está disponible en: [Repositorio del Proyecto](#)

## C. Uso de herramientas de IA generativa

Durante el desarrollo del trabajo se han utilizado herramientas de IA como Gemini o Claude principalmente para la búsqueda de bibliografía relacionada, la mejora en la redacción del informe (no para generar texto desde cero), para algunos fragmentos del código (especialmente para generar los diversos plots) y para la presentación de diapositivas del proyecto.