

Predicción de Riesgo Cardíaco

con Privacidad, Explicabilidad y Equidad

UCI Heart Disease Dataset · Aprendizaje Avanzado 2025/2026

Marcos Francés Requena · Luna Camacho Boluda

Irene Fátima Robles Cano · Ángel Adrián Bustios Cancino

Grado en Ingeniería en Inteligencia Artificial · Universidad de Alicante

Índice de Contenidos

1

Introducción

Motivación, objetivos y problemática

2

Descripción del Problema y los Datos

Dataset, EDA y problemáticas identificadas

3

Metodología

Preprocesamiento, modelos y técnicas

4

Experimentos y Resultados

GridSearch, SHAP, privacidad y fairness

5

Discusión

Interpretación, limitaciones e implicaciones éticas

6

Conclusiones

Síntesis de resultados y aportaciones

Introducción

Privacidad

Datos médicos sensibles regulados por RGPD (art. 9). No pueden centralizarse entre hospitales sin violar la normativa.

Equidad

Los modelos pueden agravar sesgos existentes. Riesgo de desigualdades en diagnóstico según sexo, edad u otros atributos sensibles.

Explicabilidad

Los sistemas de IA en salud son 'cajas negras'. El RGPD (art. 22) exige explicaciones comprensibles para decisiones automatizadas.

Objetivo: Sistema de predicción cardíaca sobre UCI Heart Disease Dataset integrando aprendizaje federado, SMOTETomek y SHAP, con evaluación de equidad por sexo y edad.

3. Descripción del Problema y los Datos — Dataset

Tarea: Clasificación binaria supervisada — $f: \mathbb{R}^{13} \rightarrow \{0,1\}$ | $y_i = 0$ (sano) si num=0 / $y_i = 1$ (enfermedad) si num > 0

Característica	Valor
Fuente	UCI Machine Learning Repository, id=45
Instancias	303 (297 tras eliminar nulos)
Features	13 variables clínicas
Variable objetivo	num binarizada: 0 (sano) / 1 (enfermedad)
Distribución	53,87 % clase 0 / 46,13 % clase 1
Valores ausentes	ca (4 nulos) y thal (2 nulos) — eliminados con dropna()
Licencia	CC BY 4.0

Variables numéricas continuas


- ❑ *age* -> edad
- ❑ *trestbps*, -> presión arterial en reposo
- ❑ *chol* -> colesterol
- ❑ *thalach* -> frecuencia cardiaca máxima
- ❑ *oldpeak* -> depresión del segmento ST
- ❑ *ca* -> número de vasos principales

Variables categóricas

- ❑ *sex* -> sexo
- ❑ *cp* -> tipo dolor torácico
- ❑ *fbs* -> glucemia en ayunas
- ❑ *restecg* -> resultado del ECG en reposo
- ❑ *exang* -> angina inducida por ejercicio
- ❑ *slope* -> pendiente del segmento ST
- ❑ *thal* -> resultado de la prueba de talio


3. EDA — Distribución y Variables Numéricas

Fig. 1 — Distribución de la variable objetivo



- Clase 0 (Sano): 160 muestras (53,87%)
 - Clase 1 (Enfermedad): 137 muestras (46,13%)
- Desbalance moderado — puede penalizar el Recall


Fig. 2 — Distribución de variables numéricas



- age: distribución bimodal
- trestbps y chol: normales con cola derecha
- oldpeak: asimetría positiva, outliers ~ 6 · ca: discreta (0-3)

3. EDA — Boxplots y Valores Atípicos

Fig. 3 — Boxplots de variables numéricas



Outliers relevantes:

chol

máx 564 mg/dl · p75: 275

trestbps

máx 200 mmHg · p75: 140


oldpeak

máx 6,2 · p75: 1,6

→ Justifica imputación
con la mediana (robusta ante outliers)

3. EDA — Matriz de Correlación

Fig. 4 — Matriz de correlación de Pearson



Variables más correlacionadas con num:

ca

$r = +0,52$

thal

$r = +0,51$

oldpeak

$r = +0,50$

cp

$r = +0,40$

exang

$r = +0,39$

thalach

$r = -0,42$

chol y fbs: correlación casi nula ($r < 0,07$)

3. Problemáticas Identificadas

Privacidad

- Datos de múltiples hospitales → centralización imposible bajo RGPD (art. 9) y AI Act
- El AI Act clasifica estos sistemas como de ALTO RIESGO
- Solución propuesta: Aprendizaje Federado — cada cliente entrena localmente sin exponer datos

Escasez de Datos y Desbalance

- Solo 297 instancias → alto riesgo de sobreajuste
- Desbalance 53,87% / 46,13% — moderado pero relevante clínicamente
- Falso negativo (clasificar enfermo como sano) tiene consecuencias graves → priorizar Recall

Falta de Transparencia

- Modelos IA son 'cajas negras' — médicos no confían sin explicación
- RGPD art. 22: derecho a explicación en decisiones automatizadas
- Solución: SHAP sobre Random Forest para explicabilidad local y global

4. Metodología — Preprocesamiento y Baseline

1

Eliminación de nulos

`dropna()` — 6 filas eliminadas (ca: 4, thal: 2)

2

Binarización del target

num $\rightarrow$ 0 si num=0 (sano), 1 si num>0 (enfermedad)

3

División train/test

80/20 estratificada (`random_state=42`) — sin data leakage

4

Imputación

Numéricas: mediana (robusta a outliers) · Categóricas: moda

5

Escalado

`StandardScaler` sobre variables numéricas continuas

6

Codificación

`OneHotEncoder(drop='first')` para evitar multicolinealidad

7

Balanceo: SMOTETomek

Solo en entrenamiento: 128 $\rightarrow$ 117 (clase 0), 109 $\rightarrow$ 117 (clase 1)

Baseline: Regresión Logística

Solver `lbfgs` · regularización ℓ^2 ($C=1$) · CV estratificada 5 folds · métrica: AUC-ROC y Recall

4. Metodología — Aprendizaje Federado (Privacidad)



$$w_{\text{global}} = \Sigma(nk \cdot wk) / \Sigma nk \rightarrow \text{Promedio ponderado por tamaño de partición}$$

SMOTETomek local: balanceo completamente privado — ninguna muestra (real ni sintética) abandona el cliente

R (rondas):

15

λ (regularización):

0,01

E (épocas locales):

100

4. Metodología — Modelos y Explicabilidad SHAP

Random Forest

T árboles sobre muestras bootstrap · $m = \sqrt{d}$ características por nodo

Doble aleatoriedad: reduce varianza sin aumentar sesgo — robusto ante sobreajuste en datasets pequeños

T=500 · criterio: Gini · hiperparámetros por GridSearch

SVM (lineal, RBF, polinomial, sigmoide)

Hiperplano de máximo margen con variables de holgura · kernel RBF: $\kappa(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$

Efectivo en espacios de alta dimensión con pocas muestras

GridSearch sobre C, gamma, degree, coef0

Gradient Boosting & AdaBoost

GB: construcción secuencial — cada árbol predice pseudo-residuos del modelo acumulado

AdaBoost: peso adaptativo sobre muestras mal clasificadas

Conf. GB: M=100, $\eta=0,1$, dmax=3 · optimizados con GridSearch

SHAP — TreeExplainer sobre el mejor RF: valores Shapley exactos $O(T \cdot L \cdot d)$ · propiedades: eficiencia, simetría, nulidad, aditividad · análisis global + waterfall local (RGPD)


5. Experimentos — GridSearch: Comparativa de Modelos

Modelo	AUC-ROC	F1	Recall	Precision	Accuracy
Baseline (LogReg)	0,8906 ±0,072	0,7861 ±0,084	0,7511 ±0,110	0,8349 ±0,093	0,8140 ±0,075
SVM lineal	0,9587 ±0,025	0,8727 ±0,067	0,8571 ±0,110	0,8889 ±0,026	0,8833 ±0,040
SVM RBF	0,9609 ±0,017	0,8727 ±0,018	0,8571 ±0,048	0,8889 ±0,030	0,8833 ±0,008
SVM polinomial	0,9386 ±0,026	0,8519 ±0,047	0,8214 ±0,088	0,8846 ±0,048	0,8667 ±0,025
SVM sigmoide	0,9576 ±0,028	0,8727 ±0,044	0,8571 ±0,084	0,8889 ±0,027	0,8833 ±0,025
Random Forest	0,9269 ±0,024	0,7692 ±0,030	0,7143 ±0,066	0,8333 ±0,028	0,8000 ±0,022
Gradient Boosting	0,9196 ±0,021	0,8000 ±0,025	0,7857 ±0,053	0,8148 ±0,024	0,8167 ±0,017
AdaBoost	0,9129 ±0,016	0,7778 ±0,020	0,7500 ±0,052	0,8077 ±0,023	0,8000 ±0,014

SVM RBF: mejor modelo — AUC-ROC 0,9609 · Recall 0,8571 · supera baseline en +10,6 pp en Recall · baja varianza (±0,017)


5. Experimentos — Comparativa Visual de Métricas

Fig. 5 — Comparativa de métricas (barras de error: desviación estándar, CV=5)




5. Experimentos — Comparativa Visual de Métricas

Fig. 6 — Mapa de calor de métricas (verde=alto, amarillo=bajo)




5. Experimentos — Ranking y Variabilidad Inter-fold

Fig. 7 — Ranking por AUC-ROC (umbral 0,90 en rojo)



5. Experimentos — Ranking y Variabilidad Inter-fold

Fig. 8 — Distribución AUC-ROC, F1 y Recall en 5 folds CV



5. Experimentos — Ranking y Variabilidad Inter-fold

Mejores hiperparámetros (GridSearch):

SVM RBF	C=1, gamma=0,01
SVM lineal	C=0,01
Random Forest	n_est=200, sqrt
Grad. Boosting	lr=0,01, depth=3
AdaBoost	depth=2, lr=0,1

5. Explicabilidad — Análisis SHAP Global

Fig. 10 — SHAP Summary Plot (beeswarm)
Rojo=valor alto · Azul=valor bajo





Fig. 11 — Importancia global (mean |SHAP|)



5. Explicabilidad — SHAP Dependence Plots y Waterfall

Fig. 12 — SHAP Dependence Plots: top 4 características





Fig. 13 — Waterfall: Paciente 0 (real: sano)



5. Experimentos — Curvas de Privacidad–Utilidad

Método: ruido gaussiano diferencial $\sigma = \Delta f / \epsilon$ añadido al conjunto de entrenamiento · 10 realizaciones independientes por nivel de ϵ

Fig. 14 — Privacidad-Utilidad: Random Forest
Línea verde = AUC sin ruido (0,9213)





Fig. 15 — Comparativa: Baseline, RF, GB
Mayor ϵ = menor privacidad



→ AUC-ROC cae para $\epsilon \leq 0,5$ · Se estabiliza $>0,9$ para $\epsilon \geq 5$ · Privacidad diferencial moderada viable sin degradación significativa del rendimiento

5. Análisis de Fairness — Sesgo por Sexo

Métricas por grupo sensible (sexo) en test:

Modelo	AUC Global	AUC Mujeres	AUC Hombres	F1 Mujeres	F1 Hombres
Baseline (LogReg)	0,9498	1,0000	0,9075	0,8000	0,8571
SVM RBF	0,9609	1,0000	0,9350	1,0000	0,8571

Indicadores de equidad (ideal → 0 para diferencias, ideal → 1 para ratio):

Demographic Parity Difference	<i>Ideal: ↓ 0</i>	Baseline: 0,4801	SVM: 0,4275
Equal Opportunity Difference	<i>Ideal: ↓ 0</i>	Baseline: 0,1733	SVM: 0,1600
Equalized Odds Difference	<i>Ideal: ↓ 0</i>	Baseline: 0,1875	SVM: 0,1875
Disparate Impact Ratio	<i>Ideal: ↑ 1</i>	Baseline: 0,1798	SVM: 0,2697


Fig. 16 — Heatmap fairness

Fig. 17 — Indicadores vs umbral 0,10

Fig. 18 — Curvas ROC por grupo

5. Fairness — Visualizaciones

Fig. 16 — Heatmap de métricas por grupo sensible (izq=baseline, der=SVM RBF)



5. Fairness — Visualizaciones

Fig. 17 — Indicadores de fairness (línea roja = umbral 0,10)





Fig. 18 — Curvas ROC por grupo sensible (sexo)



6. Conclusiones

Rendimiento

SVM RBF es el mejor modelo (AUC-ROC=0,9609, Recall=0,8571). La complejidad del modelo NO es el factor determinante con datos pequeños: la diferencia entre mejor y peor es <5 pp — el límite lo impone el tamaño y calidad de los datos.

Explicabilidad SHAP

Variables clave: thal (defecto reversible), cp (asintomático), ca (vasos por fluoroscopia) y oldpeak (depresión ST). Waterfall plots cumplen los requisitos de trazabilidad del RGPD y el AI Act.

Privacidad

SMOTETomek local es compatible con aprendizaje federado. Privacidad diferencial moderada es viable sin degradación significativa del rendimiento.

Equidad

Sesgo sistemático por sexo (DIR=0,2697, muy por debajo del umbral 0,80). Las métricas globales son INSUFICIENTES — la evaluación desagregada por grupos sensibles debe ser estándar en sistemas de apoyo al diagnóstico médico.

¡Gracias por vuestra atención!

Predicción de Riesgo Cardíaco — Privacidad · Explicabilidad · Equidad

Marcos Francés · Luna Camacho · Irene Robles · Ángel Bustios

Universidad de Alicante · Aprendizaje Avanzado 2025/2026